

مذكرة الإحصاء الوصفي

المذكرة الأولى

Foundations of Descriptive Statistics for AI

تغطي هذه المذكرة:

1. مقدمة في الإحصاء الوصفي
2. تنظيم وتمثيل البيانات
3. التمثيل البياني للبيانات
4. مقاييس النزعة المركزية
5. مقاييس التشتت
6. الموقع النسبي وتقسيم البيانات
7. شكل التوزيع
8. مفاهيم رياضية مهمة للإحصاء الوصفي
9. Python الإحصاء الوصفي باستخدام

الفصل الأول: مقدمة في الإحصاء الوصفي

ما هو علم الإحصاء؟ 1.

تخيل أنك تعمل في شركة ضخمة تباع منتجاتها لملايين العملاء. كل يوم يتراكم لديك كم هائل من الأرقام: أعمار العملاء، كميات الشراء، المواقع الجغرافية، ساعات الزيارة. هذا الكم الهائل من الأرقام، في حد ذاته، لا يخبرك بشيء مفيد. الإحصاء هو الأداة التي تحول هذه الأرقام الخام إلى معرفة ورؤى قابلة للتطبيق.

الإحصاء (Statistics)

علم يُعنى بجمع البيانات وتنظيمها وتحليلها وتفسيرها واستخلاص النتائج منها لمساعدتنا على فهم الظواهر واتخاذ القرارات في ظل حالة من عدم اليقين.

الإحصاء ليس مجرد حساب معدلات وأرقام. بل هو منهج تفكير يساعدنا على:

- وصف ما نراه في البيانات (Descriptive Statistics)
- استنتاج ما لا نراه بعد، أو ما ينطبق على الكل من مجرد عينة (Inferential Statistics)
- اكتشاف الأنماط والعلاقات بين المتغيرات
- اتخاذ قرارات مدعومة بالدليل لا بالتخمين

مثال توضيحي

لديك 1000 طالب في امتحان. كيف تصف أداءهم بجملة واحدة؟ الإحصاء يُمكنك من قول: 'متوسط الدرجات 75 بانحراف معياري 10'، وهذه الجملة الواحدة تحمل معلومات أكثر بكثير من سرد 1000 درجة.

مبادئ علم الإحصاء 2.

يقوم علم الإحصاء على مبادئ جوهرية يجب فهمها قبل الدخول في التفاصيل:

البيانات التي نجمعها يجب أن تمثل الواقع بأمانة. إذا جمعنا بيانات عن الطلاب: (Representation) المبدأ الأول - التمثيل من مدرسة واحدة فقط، فنناجنا لن تمثل كل الطلاب.

أي تحليل إحصائي يجب أن يكون قابلاً للتكرار والتحقق. إذا كررت نفس التجربة بنفس الطريقة، يجب أن تحصل على نفس النتائج (أو نتائج متقاربة). (Reproducibility) المبدأ الثاني - التكرار

الإحصاء يعترف دائماً بوجود هامش من الخطأ وعدم اليقين. لا توجد نتيجة: (Uncertainty) المبدأ الثالث - عدم اليقين إحصائية مؤكدة 100%، بل توجد نتائج بدرجات ثقة مختلفة.

هل نقيس ما نريد فعلاً قياسه؟ إذا أردنا قياس الذكاء وقسنا فقط حفظ الأرقام، فالقياس: (Validity) المبدأ الرابع - الصلاحية غير صالح.

(AI Connection): الصلة بالذكاء الاصطناعي

(تحيز). عندما Bias في تعلم الآلة، هذه المبادئ تظهر بوضوح: عندما تُدرَّب نموذجاً على بيانات غير ممثلة، تحصل على الإحصاء هو الأساس الذي يمنع هذه الأخطاء. Overfitting لا تتحقق من نتائجك، تقع في

Descriptive و Inferential Statistics الفرق بين 3.

. هذا التمييز جوهري جداً. دعني أشرحه من خلال تخيل سيناريو: شركة تريد أن تعرف ما إذا كان منتجها الجديد يُعجب العملاء

المعيار	Descriptive Statistics	Inferential Statistics
الهدف	وصف البيانات الموجودة أمامنا	الاستنتاج والتنبؤ بما هو أبعد من البيانات
السؤال	ما الذي يحدث في هذه البيانات؟	هل ما نراه ينطبق على الكل؟
الأدوات	المتوسطات، الرسوم، جداول التوزيع	الاختبارات الإحصائية، الفترات الثقة
المخاطر	لا توجد تعميم = أقل خطأ	التعميم قد يكون خاطئاً إذا كانت العينة مشوهة
المثال	متوسط درجات 100 طالب = 75	يُرجَّح أن متوسط كل الطلاب قريب من 75

:مثال توضيحي

يقول: 'هؤلاء الـ 500 راضون Descriptive شركة استطلعت 500 عميل وحصلت على متوسط رضا 4.2 من 5. الـ يقول: 'نستنتج أن جميع عملاء الشركة (ربما مليون شخص) رضاهم يقع بين 4.0 و 4.4 Inferential بمتوسط 4.2. الـ %95 بثقة 95'.

(AI Connection): الصلة بالذكاء الاصطناعي

، (EDA - Exploratory Data Analysis) لفهم بياناتك Descriptive Statistics تبدأ دائماً بـ AI، في بناء نماذج لتقييم أداء النموذج والتعميم على بيانات جديدة Inferential Statistics ثم تستخدم

Machine Learning و AI لماذا نحتاج الإحصاء في 4.

Neural بسيطة أو Regression الذكاء الاصطناعي في جوهره هو إحصاء متطور. كل خوارزمية تعلم آلة، سواء كانت معقدة، تستند إلى مفاهيم إحصائية أساسية. دعني أريك الصلة العضوية Network

- لفهم توزيع بياناتك، اكتشاف Descriptive Statistics فهم البيانات قبل النمذجة: قبل بناء أي نموذج، تحتاج تحديد العلاقات بين المتغيرات (Outliers) القيم الشاذة.
- Linear Regression اختبار الخوارزمية المناسبة: بعض الخوارزميات تفترض توزيعاً معيناً للبيانات (مثل التي تفترض توزيع الأخطاء الطبيعي). (بدون فهم إحصائي لن تعرف متى تستخدم كل خوارزمية هي مفاهيم إحصائية بحتة. فهمها العميق يُمكنك من تقييم MSE, RMSE, R² تقييم النموذج: المقاييس مثل نموذجك بشكل صحيح.

- Feature Engineering: (Normalization, Standardization) تحويل المتغيرات وتوحيدها على مفاهيم الانحراف المعياري والمتوسط.
- الإحصاء يساعدك على اكتشاف التحيز في بياناتك ومعالجته (Bias Prevention) منع التحيز.

(AI Connection): الصلة بالذكاء الاصطناعي
خذ مثلاً عملياً: نموذج لتشخيص المرض. إذا كانت 95% من البيانات سلبية و 5% إيجابية، ونموذجك يتنبأ دائماً بالسلب، ف1-Score دقته ستكون 95%! الإحصاء يُريك أن هذه الدقة مضللة ويُعلمك استخدام مقاييس أفضل مثل

البيانات وأنواعها 5.

البيانات هي المادة الخام للإحصاء وللذكاء الاصطناعي. لكن ليست كل البيانات متساوية. قبل أن تفعل أي شيء بالبيانات، يجب أن تفهم طبيعتها.

تخيل أنك جمعت معلومات عن 100 موظف: أسماءهم، أعمارهم، رواتبهم، قسمهم، تقييمهم الوظيفي (ممتاز/جيد/مقبول). هذه كلها 'بيانات'، لكن كل نوع يختلف عن الآخر جوهرياً.

(Numerical Data) أ. البيانات الرقمية

هي بيانات تُعبّر عن كميات قابلة للقياس والحساب. تنقسم إلى نوعين:

Discrete Data (البيانات المنفصلة)	قيم محددة لا يمكن أن توجد بينها قيم وسطية. مثال: عدد الأبناء (1، 2، 3)، لا يوجد 'شخص 2.5'. عدد النقرات، عدد المعاملات: ML لديه 2.5 ابن. 'في'
Continuous Data (البيانات المستمرة)	ML: يمكن أن تأخذ أي قيمة ضمن نطاق. مثال: الطول (1.75م، 1.753م، 1.7534م). (في) درجة الحرارة، السرعة، الوزن.

(Categorical Data) ب. البيانات الفئوية

بيانات تُمثّل فئات أو تصنيفات لا قيماً رقمية حقيقية. مثل الجنس (ذكر/أنثى)، اللون، القسم الوظيفي. حتى لو أعطيناها أرقاماً (ذكر=1، أنثى=2) فالأرقام هنا مجرد رموز ولا يمكن حساب متوسطها.

(Time Series Data) ج. بيانات السلاسل الزمنية

بيانات مرتبطة بالزمن. مثال: سعر سهم على مدار سنة، درجات الحرارة اليومية، مبيعات شهرية. ما يميزها أن الترتيب الزمني مهم جداً، والقيمة في لحظة ما تعتمد على القيم السابقة.

(AI Connection): الصلة بالذكاء الاصطناعي

One-Hot مثل (Encoding) البيانات الرقمية تُدخّل مباشرة في معظم النماذج. البيانات الفئوية تحتاج تحويل: ML في فهم نوع ARIMA أو LSTM بيانات السلاسل الزمنية تحتاج نماذج خاصة مثل Label Encoding أو Encoding. البيانات يُحدد مسار عملك بأكمله!

6. مفهوم المجتمع والعينة

ML. هذا المفهوم من أهم المفاهيم الإحصائية، ويؤثر مباشرة على كيفية جمع البيانات وتفسير النتائج في

Population (المجتمع)	كل الأفراد أو العناصر الذين نريد دراستهم. مثال: جميع مستخدمي تطبيق معين (قد يكون 100 مليون شخص).
-------------------------	--

Sample (العينة)	مجموعة فرعية منتقاة من المجتمع لإجراء الدراسة عليها. مثال: 10,000 مستخدم مُختارون بطريقة عشوائية.
-----------------	---

لماذا نحتاج العينة؟ لأنه في معظم الحالات يستحيل أو يكلف كثيراً دراسة كل المجتمع. نكتفي بعينة تمثيلية ونعمّم النتائج على المجتمع كله.

مثال توضيحي: شركة تريد معرفة رضا عملائها (10 مليون عميل). (دراسة الكل: مستحيل من ناحية الوقت والتكلفة. الحل: نختار عينة عشوائية من 1000 عميل، ندرسها، ونعمّم النتائج. لكن هنا يأتي الخطر: هل العينة ممثلة فعلاً؟ إذا اخترنا فقط عملاء من مدينة واحدة، ستكون العينة منحازة).
--

المعيار	Population	Sample
الرمز الإحصائي	(μ, σ) حروف يونانية	$(\bar{x}, s)$ حروف لاتينية
الحجم	N	n
القصد	الحقيقة الكاملة	تقدير الحقيقة
ML الاستخدام في	نادر (نادراً ما نملك البيانات الكاملة)	Training/Test data - هو الأساس هي عينات

(AI Connection) الصلة بالذكاء الاصطناعي: هي عينة من المجتمع الكلي. النموذج يتعلم من العينة ويُعمّم على المجتمع (Training Set) مجموعة التدريب، ML في الاختبار قدرة النموذج على التعميم (Test Set) من أهم الخطوات: نحتفظ بجزء من العينة Train/Test Split لهذا يُعدّ
--

7. أنواع المتغيرات

المتغير هو أي خاصية أو صفة يمكن قياسها أو تصنيفها على الأفراد. فهم أنواع المتغيرات يُحدد الأدوات الإحصائية والخوارزميات التي يمكن استخدامها.

أ. المتغيرات الكمية (Quantitative Variables)

تُمثل كميات قابلة للقياس وإجراء العمليات الحسابية عليها. مثل: العمر، الراتب، الوزن، الطول، درجة الحرارة. يمكن حساب المتوسط، الانحراف المعياري، وإجراء كل العمليات الرياضية عليها.

ب. المتغيرات النوعية (Qualitative Variables)

تُمثل صفات أو تصنيفات لا يمكن قياسها كمياً. مثل: الجنس، اللون، القسم الوظيفي، النوع. حتى لو أعطيت قيمة رقمية (مثل: ذكر=1، أنثى=0)، هذه الأرقام مجرد رموز - لا معنى لحساب المتوسط من جمعها.

مثال توضيحي

عندي متغير 'القسم': مبيعات=1، تسويق=2، هندسة=3. لو أدخلت هذا الرقم مباشرة في النموذج: ML خطأ شائع في One-Hot Encoding أو Label Encoding سيقتضئ النموذج أن 'هندسة' أكبر من 'تسويق' وأن المسافة بينهما 1، وهذا خطأ! الحل: بوعى.

(AI Connection): الصلة بالذكاء الاصطناعي

Feature رقمية جاهزة للاستخدام. المتغيرات النوعية = تحتاج Features = المتغيرات الكمية: ML في ML. قبل الاستخدام. التمييز بينهما من أوائل الخطوات في أي مشروع Engineering.

8. مستويات القياس (Levels of Measurement)

هذا المفهوم يُضيف طبقة عمق إضافية فوق مجرد تصنيف البيانات. كل مستوى قياس يُحدد ما يمكن وما لا يمكن فعله إحصائياً بالبيانات.

أولاً: المقياس الاسمي (Nominal Scale)

يُصنّف البيانات في فئات دون أي ترتيب أو قيمة رقمية حقيقية. مثل: لون السيارة (أحمر، أزرق، أبيض)، جنسية الشخص. نوع الدم. لا توجد أي علاقة رياضية بين الفئات.

- (Pie Chart) رسم مخطط دائري، (Mode) يمكن: حساب التكرارات، المنوال
- لا يمكن: حساب المتوسط، إجراء أي عمليات حسابية

ثانياً: المقياس الرتبي (Ordinal Scale)

يُصنّف البيانات في فئات مُرتّبة، لكن المسافة بين الفئات غير محددة. مثال: تقييم رضا العملاء (راضٍ جداً، راضٍ، محايد، غير راضٍ، غير راضٍ جداً). (الترتيب واضح، لكن المسافة بين 'راضٍ' و'راضٍ جداً' لا نستطيع قياسها).

- (Median) حساب الوسيط + Nominal يمكن: كل ما يمكن في

- لا يمكن: حساب المتوسط الحسابي بشكل صحيح (بعض الدراسات تغفلها تقريبياً)

(Interval Scale) ثالثاً: المقياس الفترى

- مقياس رقمي بمسافات متساوية بين القيم، لكن بدون صفر حقيقي. مثال كلاسيكي: درجة الحرارة بالسيليزيوس (صفر درجة $^{\circ}\text{C}$ و 20°C مساوية للمسافة بين 20°C و 30°C). لا يعني 'لا توجد حرارة'، السنة الميلادية. المسافة بين 10
- يمكن: المتوسط، الانحراف المعياري، المسافات
 - (لأن الصفر ليس حقيقياً $^{\circ}\text{C}$ ضعف 20°C لا يمكن القول '40') لا يمكن: النسب

(Ratio Scale) رابعاً: مقياس النسبة

- أعلى مستويات القياس. مقياس رقمي بمسافات متساوية وصفر حقيقي (يعني غياب تام للخاصية. مثال: الوزن، الطول). الراتب، عدد المبيعات. الصفر هنا حقيقي: صفر كيلوجرام يعني لا وزن
- يمكن: كل العمليات الإحصائية، بما فيها النسب (راتب 60,000 ضعف راتب 30,000)

المستوى	الترتيب	مسافات متساوية	صفر حقيقي	مثال	عمليات ممكنة
Nominal	لا	لا	لا	لون السيارة	Mode، تعداد
Ordinal	نعم	لا	لا	تقييم الرضا	+ Median, Range
Interval	نعم	نعم	لا	درجة حرارة	+ Mean, SD
Ratio	نعم	نعم	نعم	الوزن، الراتب	كل العمليات

(AI Connection): الصلة بالذكاء الاصطناعي

One-Hot Encoding مع Nominal → Classification. مستوى القياس يُحدد نوع النموذج المناسب: ML في Ordinal Encoding. Interval/Ratio → Regression. Label Encoding يمكن Ordinal →

!نموذج يعمل مع بيانات رقمية مستمرة. تجاهل مستوى القياس يُفضي إلى نماذج خاطئة

9. مصادر البيانات وأنواعها

Structured vs Unstructured Data

Excel هي البيانات التي تأتي في شكل جدولي واضح: أعمدة وصفوف. مثل بيانات (Structured Data) البيانات المنظمة كل خلية لها معنى محدد وُبعد محدد. SQL أو قاعدة بيانات

، هي البيانات التي لا تأتي في قالب محدد. النصوص، الصور، الأصوات (Unstructured Data) البيانات غير المنظمة مقاطع الفيديو، رسائل البريد الإلكتروني. 80-90% من بيانات العالم غير منظمة

مثال توضيحي

شركة تجارة إلكترونية لديها: بيانات منظمة (جداول المبيعات والعملاء)، وبيانات غير منظمة (آراء العملاء المكتوبة، صور AI/Deep المنتجات، تسجيلات مركز الاتصال). (في الإحصاء الوصفي التقليدي، نتعامل أساساً مع البيانات المنظمة. في Learning، نتعامل مع كلا النوعين،

10. Dataset و Data Matrix مفهوم الـ

Dataset (مجموعة البيانات)	مجموعة منظمة من البيانات المجمعة لغرض معين. في السياق التقليدي: جدول بيانات. في البيانات التي يتعلم منها النموذج: ML.
Data Matrix (مصفوفة البيانات)	كل (Observation) كمصفوفة. كل صف يُمثل مشاهدة Dataset التمثيل الرياضي للـ. لو عندك 1000 صف و 20 عمود، مصفوفتك حجمها (Feature) عمود يُمثل متغيراً 1000×20.

Python هذا التمثيل المصفوفي ليس مجرد تجريد رياضي، بل هو الطريقة الفعلية التي تُخزن بها البيانات في الكمبيوتر. في (NumPy/Pandas)، dataset كل هو في الأساس مصفوفة dataset.

11. Features و Labels

(Supervised Learning): هذان المفهومان محوريان في تعلم الآلة المُشرف.

Features (المتغيرات/الخصائص)	Input Variables, Independent Variables, Predictors, X. الأعمدة المُدخلة للنموذج. تُسمى أيضاً. مثال: عمر المريض، ضغط دمه، نبضه القلبي.
Labels / Target (التسمية/الهدف)	Output Variable, Dependent Variable, Response Variable, Y. المتغير الذي نريد التنبؤ به. يُسمى أيضاً. مثال: هل المريض مصاب بالمرض أم لا (0/1).

مثال توضيحي: سعر المنزل. النموذج يتعلم: Label. المساحة، عدد الغرف، الحي، سنة البناء: Features: مشروع التنبؤ بسعر المنزل من بيانات تاريخية، ثم يُنبئ بسعر منزل جديد لم يره من قبل Label والـ Features العلاقة بين الـ

12. Observation و Instance مفهوم الـ

Observation / Instance (المشاهدة)	يُمثل مشاهدة واحدة لظاهرة ما أو بيانات كيان واحد. مثال. Dataset صف واحد في الـ. بيانات موظف واحد، مريض واحد، منزل واحد.
--	---

نعني أن لدينا 10,000 صف من البيانات، كل صف يمثل حالة 'observation' به Dataset 10,000: عندما نقول. لأن قلة البيانات تؤدي إلى نماذج ضعيفة ML واحدة. هذا الرقم مهم جداً في

(AI Connection): الصلة بالذكاء الاصطناعي

Observations تحتاج مليارات الـ GPT البيانات هي البنزين لمحرك الذكاء الاصطناعي 'النماذج الحديثة مثل' يُمكنك من قراءة أي ورقة (Dataset, Observations, Features, Labels) للتدريب. فهم هذه المفاهيم الأساسية يفهم حقيقى AI بحثية فى

الفصل الثاني: تنظيم وتمثيل البيانات

لديك مئات أو آلاف الأرقام الخام. كيف تُحوّلها إلى معلومات مفهومة؟ هذا هو الهدف الجوهرى من هذا الفصل. تنظيم البيانات هو الخطوة التي تسبق أي تحليل أو رسم أو نمذجة.

Frequency Distribution الجداول الإحصائية و 1.

تخيل درجات 50 طالب في امتحان. عرضها كقائمة من 50 رقم لا يُخبرنا بشيء. لكن لو جمعنا هذه الأرقام في جدول يُظهر كم مرة ظهرت كل درجة أو كل فئة من الدرجات، ستظهر الصورة الكاملة فجأة.

Frequency Distribution (توزيع التكرار)	جدول يُظهر كل قيمة (أو فئة من القيم مع عدد مرات ظهورها في البيانات). هو الطريقة الأساسية لتلخيص البيانات.
---	---

أ. Frequency Table (جدول التكرار)

للبينات المتقطعة أو الفئوية، ننشئ جدولاً يُدرج كل قيمة وعدد تكرارها. مثلاً لو سألنا 20 شخصاً عن لونهم المفضل:

اللون	التكرار (f)	التكرار النسبي (rf)	التكرار التراكمي (cf)
أزرق	8	0.40 (40%)	8
أحمر	5	0.25 (25%)	13
أخضر	4	0.20 (20%)	17
أصفر	3	0.15 (15%)	20
المجموع	20	1.00 (100%)	-

ب. Relative Frequency (التكرار النسبي)

يُحوّل الأعداد المطلقة إلى نسب مئوية، مما يُسهّل: $rf = f / n$. هو نسبة تكرار القيمة إلى إجمالي عدد المشاهدات. الصيغة المقارنة بين مجموعات مختلفة الحجم. هل 8 طلاب ناجحون كثير؟ يعتمد على حجم الفصل! لكن 80% ناجحون واضحة للجميع.

ج. Cumulative Frequency (التكرار التراكمي)

'هو مجموع التكرارات من البداية وحتى قيمة معينة. يُجيب على أسئلة من نوع 'كم طالباً حصل على 70 درجة أو أقل؟ لاحقاً Percentiles يُستخدم لحساب الـ

(AI Connection): الصلة بالذكاء الاصطناعي

أول ما تفعله هو رسم توزيع كل (EDA) مفهوم التوزيع هو الأساس. عندما تُحلل بيانات قبل بناء النموذج، ML في هل البيانات موزعة بشكل طبيعي؟ هل هناك تحيز؟ هل هناك قيم شاذة؟ كل هذا يظهر من جدول أو رسم التوزيع. feature.

2. Grouped Data و Class Intervals

للبيانات الكمية المستمرة، لا يمكن عمل جدول لكل قيمة فردية (لأن القيم قد تكون لا متناهية). (الحل: تُقسّم البيانات إلى فئات (Classes)).

Class Interval (الفئة أو المجال)	نطاق من القيم يُجمع معاً في فئة واحدة. مثال: 70-60 (يضم كل الدرجات من 60 وحتى أقل من 70)
--	--

المصطلحات الأساسية للفئات

- حدود الفئة: (الحدود الفعلية للفئة بحيث لا تتداخل الفئات. مثال: Class Boundaries 69.5 - 59.5)
- عرض الفئة: (الفرق بين حد الفئة العلوي والسفلي. مثال: Class Width 10 = 60 - 70)
- نقطة منتصف الفئة: (متوسط حدي الفئة. مثال: $65 = \frac{70+60}{2}$). تُستخدم لتمثيل الفئة في الحسابات.
- فئات مفتوحة النهاية: (فئات بدون حد سفلي أو علوي. مثال: 70 فأكثر. مشكلتها Open-ended Classes. أننا لا نستطيع حساب المتوسط لها).

مثال توضيحي

درجات 30 طالب. بدلاً من إدراج كل درجة، نُقسّمها: 60-50: (3 طلاب، 70-60: (8 طلاب، 80-70: (12 طالب، 100-90: (2 طالب. الآن نرى فوراً أن معظم الطلاب في نطاق 80-70: 5 [80-90)

3. Data Binning و Discretization

هذا المفهوم ليس مجرد أداة إحصائية تقليدية، بل (bins) هو تحويل البيانات المستمرة إلى فئات منفصلة Data Binning. ML له تطبيقات مهمة جداً في

Data Binning	مثال: تحويل الأعمار [18-0]: صغير. (buckets/bins) تقسيم بيانات مستمرة إلى فئات. بالغ، [65]: +كبير: [18-65]
---------------------	---

Discretization في ML	Naive Bayes و Decision Trees تحويل متغير مستمر إلى متغير فئوي. يُستخدم في وغيرها من الخوارزميات التي تتعامل مع بيانات منفصلة بشكل أفضل
-----------------------------	--

Stem and Leaf Plot

وهو الأرقام (Stem) طريقة ذكية لتنظيم البيانات الرقمية مع الاحتفاظ بقيمتها الأصلية. تُقسّم كل رقم إلى جزأين: الجذع وهي آخر رقم. مثال: 67, 63, 61, 55, 53, 47 (Leaf) الرئيسية، والورقة

Leaves (أحاد)	Stem (عشرات)
7	4
3 5	5
1 3 7	6

يُحافظ على البيانات الخام Histogram ميزة هذا المخطط: نرى التوزيع بسرعة ونحتفظ بالقيم الأصلية. هو في الأساس

4. Ranking و Ordered Data

(.الترتيب (هو عملية ترتيب البيانات من الأصغر إلى الأكبر) أو العكس (وإعطاء كل قيمة رتبته) 1، 2، 3 (... Ranking يُستخدم في

- الذي يتطلب الترتيب (Median) حساب الوسيط
- Quartiles و Percentiles حساب
- (Outliers) اكتشاف القيم الشاذة
- Rank-based correlation مثل Spearman Correlation

مثال توضيحي

البيانات: 15، 3، 9، 21، 7. بعد الترتيب: 3، 7، 9، 15، 21. الرتب: 1→3، 2→7، 3→9، 4→15، 5→21. الوسيط هو القيمة ذات الرتبة الوسطى = 9

(AI Connection): الصلة بالذكاء الاصطناعي

Percentile، (ترتيب منتج في قائمة مبيعات) Rank-based Features: الترتيب يظهر في ML، في للترتيب RankNet) تحويل كل قيمة إلى نسبته المئوية بدلاً من قيمتها المطلقة)، وخوارزميات مثل Normalization في محركات البحث

الفصل الثالث: التمثيل البياني للبيانات

صورة تساوي ألف كلمة - هذا المبدأ أكثر صدقاً في الإحصاء وعلم البيانات من أي مجال آخر. الرسوم البيانية تُحوّل الأرقام المجردة إلى أنماط مرئية يستطيع الدماغ البشري استيعابها بسرعة. لكن الرسم الخاطئ يُضلل بدلاً من أن يُوضّح.

الرسوم الأساسية

1. Bar Chart (المخطط الشريطي)

أو للمقارنة بين مجموعات. كل شريط يُمثّل فئة، وارتفاعه يُمثّل التكرار أو القيمة (Categorical). يُستخدم للبيانات الفئوية متى تستخدمه؟ عندما تريد مقارنة قيم فئات مختلفة.

مثال توضيحي: الأعلى والتسلسل C يُظهر فوراً أن Bar Chart. $A=500$, $B=300$, $C=800$, $D=200$ مبيعات 4 منتجات: منتج الهرمي.

2. Histogram (الرسم البياني التكراري)

لكن للبيانات الكمية المستمرة. الفرق الجوهرى: الأشرطة متلاصقة (لا فراغ بينها) (لأن البيانات Bar Chart شبيهه بالـ يُظهر شكل التوزيع: هل البيانات طبيعية؟ هل هناك تحيز؟. (class interval) مستمرة. كل شريط يُمثّل فئة

Bar Chart و Histogram: الفرق بين

المعيار	Bar Chart	Histogram
نوع البيانات	فئوية (Categorical)	رقمية مستمرة (Numerical)
الأشرطة	منفصلة (مع فراغات)	متلاصقة (بدون فراغات)
المحور الأفقي	فئات غير مرتبة كمياً	قيم رقمية مرتبة
الغرض	مقارنة فئات	إظهار التوزيع

(AI Connection): الصلة بالذكاء الاصطناعي: هل توزيعه طبيعي؟ هل يحتاج feature لفهم توزيع كل EDA هو أول أداة تستخدمها في Histogram الـ ML، في Normalization Outliers؟ كل هذا واضح من الـ Histogram.

3. Box Plot (مخطط الصندوق والشارب)

القيمة، (Q3) الربع الثالث، (Q2) الوسيط، (Q1) يُلخّص 5 إحصاءات جوهرية في رسم واحد: القيمة الدنيا، الربع الأول بصرياً Outliers القصوى. هو الأداة الأقوى لاكتشاف الـ

(Median). الخط داخل الصندوق هو الوسيط. (IQR هذا هو الـ) Q1 إلى Q3 الصندوق يمتد من Box Plot بنية الـ. Outliers = النقاط خارج الشوارب. IQR× تمتد لأقصى القيم ضمن 1.5 (Whiskers) الشوارب.

(AI Connection) الصلة بالذكاء الاصطناعي:

قد تُفسد نموذجك. اكتشافها مبكراً Box Plot الظاهرة في Outliers قبل التدريب. الـ ML ضروري في Box Plot. يُوقر الكثير من وقت التنقيح.

4. Scatter Plot (مخطط الانتشار)

من خلاله نرى: هل هناك (x, y) بإحداثيات (observation) يُظهر العلاقة بين متغيرين كميين. كل نقطة تُمثل مشاهدة علاقة؟ هل هي طردية أم عكسية؟ هل هي خطية أم منحنية؟

مثال توضيحي:

- بين ساعات الدراسة والدرجة: إذا ظهرت النقاط في اتجاه صاعد من اليسار لليمين، هناك علاقة طردية Scatter Plot. كلما زادت ساعات الدراسة، زادت الدرجة.

(AI Connection) الصلة بالذكاء الاصطناعي:

→ إذا رأيت علاقة خطية. Regression ما قبل features هو الطريقة الأساسية لفهم العلاقة بين Scatter Plot الـ مناسب. إذا رأيت علاقة منحنية → تحتاج تحويل المتغير أو نموذج غير خطي Linear Regression.

5. Pie Chart (المخطط الدائري)

يُمثل نسب الفئات من الإجمالي. يُظهر كيف تُوزع الكل بين أجزاء. متى تستخدمه؟ فقط عندما تريد إظهار النسبة من الكل. أفضل Bar Chart، وعندما عدد الفئات قليل (أقل من 6). متى لا تستخدمه؟ عندما تريد مقارنة القيم بدقة.

6. Frequency Polygon و Area Plot

بخطوط Histogram هو رسم خطي يُمثل التوزيع. يُنشأ بربط نقاط منتصف الفئات في الـ Frequency Polygon الـ. مفيد لمقارنة توزيعين على نفس الرسم.

مشابه لكنه يملأ المنطقة تحت الخط باللون. مناسب لبيانات السلاسل الزمنية Area Plot الـ.

7. Line Chart (الرسم الخطي)

متى تستخدمه؟ عندما يكون للمحور الأفقي (Trend) مخصص للبيانات الزمنية أو المتسلسلة. يُظهر الاتجاه عبر الزمن. ترتيب زمني أو تسلسلي.

Data Science (لـ) الرسوم المتقدمة

1. Heatmap

الذي يُظهر قوة العلاقة بين كل جفت Correlation Heatmap: يُمثل البيانات بألوان في شكل مصفوفة. الأكثر استخداماً اللون الداكن = علاقة قوية. Features من الـ

(AI Connection): الصلة بالذكاء الاصطناعي
مشكلة Multicollinearity يُساعدك على اكتشاف EDA. هو خطوة أساسية في Correlation Heatmap ML. في فهم طبيعة بياناتك، Features اختيار أهم الـ (Regression).

2. Pair Plot

رسم (4×4) 16 → features شبكة 4. Dataset في Features لكل جفت من الـ Scatter Plots يُنشئ شبكة من دفعة واحدة تُعطيك صورة شاملة عن العلاقات في بياناتك. feature في المنطقة القطرية يُظهر التوزيع الفردي لكل

3. Violin Plot

أفضل (IQR الوسيط، الـ) يُظهر التوزيع الكامل للبيانات مع الإحصاءات الملخصة KDE Plot و Box Plot دمج بين (Multimodal) عندما تريد رؤية شكل التوزيع كاملاً، خاصة إذا كان متعدد القمم Box Plot من

4. KDE Plot (Kernel Density Estimation)

يُقدّر دالة الكثافة الاحتمالية للبيانات. مفيد جداً لمقارنة توزيعات Histogram. يُظهر التوزيع كمنحنى ناعم بدلاً من أشربة الـ متعددة على نفس الرسم

(AI Connection): الصلة بالذكاء الاصطناعي
(Bayesian) يساعدك في فهم كيف تبدو 'الكثافة الاحتمالية' لبياناتك. هذا الفهم مهم عند اختيار نماذج احتمالية KDE Plot Gaussian Mixture Models أو عند تطبيق (Models).

5. ECDF Plot (Empirical Cumulative Distribution Function)

Histogram ؟ منحنى يبدأ من 0% ويصل إلى 100%. أقوى من x ما نسبة البيانات أقل من أو تساوي x: يُظهر لكل قيمة لأنه يحتفظ بكل المعلومات دون فقدان ناتج عن اختيار عرض الفئات

أشكال التوزيع وقراءة الرسوم

Graphs and Shapes of Distributions

- لبياناتك، الشكل الناتج يخبرك الكثير Histogram عندما ترسم
- شكل الجرس المتمثل يدل على بيانات طبيعية. أكثر أشكال التوزيع شيوعاً: (Bell Shape) التوزيع الطبيعي في الطبيعة

- الانحراف الإيجابي: (الذي يمتد لليمين. معظم البيانات منخفضة مع قيم عالية قليلة Positively Skewed. مثال: الرواتب) معظم الناس لديهم رواتب متوسطة، قلة لديهم ملايين).
- الانحراف السلبي: (الذي يمتد لليسار. معظم البيانات مرتفعة مع قيم منخفضة قليلة Negatively Skewed. مثال: عمر التقاعد).
- توزيع ذو قممتين: (قمتان واضحتان. غالباً يدل على وجود مجموعتين مختلفتين في Bimodal Distribution البيانات).
- كل القيم متقاربة التكرار. لا توجد قيمة مسيطرة: Uniform Distribution.

(AI Connection): الصلة بالذكاء الاصطناعي

Log قد تحتاج → Skewed. التوزيع الطبيعي → معظم الخوارزميات تعمل جيداً: ML. شكل التوزيع يُحدد ما تفعله في Transform. Bimodal → Clustering قد تحتاج → Outliers. أولاً.

Visualization الناتج عن Bias

الرسوم البيانية يمكن أن تُضلل إذا لم تُستخدم بشكل صحيح. من أشهر المشاكل:

- من رقم غير صفر يُضخم الفروقات الصغيرة ويجعلها تبدو كبيرة Y بدء محور Truncated Y-axis.
- اختيار نطاق زمني معين فقط لإظهار اتجاه مرغوب فيه: Cherry-picking.
- استخدام مقاييس غير متناسبة في رسوم المقارنة: Misleading scales.

Visualization قاعدة ذهبية في

دائماً. Bar Charts. من الصفر في Y الرسم الجيد هو الذي يُظهر الحقيقة كاملة بأبسط شكل ممكن. دائماً ابدأ محور. أضف عنواناً وتسميات للمحاور. اختر الرسم الذي يُجيب على سؤالك المحدد.

الفصل الرابع: مقاييس النزعة المركزية

تخيل أنك تريد وصف أداء 50 موظف في رقم واحد. أي رقم يُمثلهم أفضل؟ هذا هو سؤال النزعة المركزية. هذه المقاييس 'تجيب على': ما القيمة الوسطية أو المركزية التي تمثل البيانات بأكملها؟

1. المتوسط الحسابي (Arithmetic Mean)

Mean = $(\sum x) / n$: للمجتمع. الصيغة μ ، للعينة $\bar{x}$: هو مجموع كل القيم مقسوماً على عددها. الرمز

مثال توضيحي:
هذا الرقم 76 (يُمثل) Mean = $380 / 5 = 76$. درجات 5 طلاب: 70، 80، 75، 90، 65. المجموع = 380.
المجموعة بأكملها.

قوية Outliers لماذا نستخدم المتوسط؟ لأنه يأخذ كل القيم بعين الاعتبار. متى لا نستخدمه؟ عندما تكون هناك

مثال توضيحي:
رواتب 5 موظفين: 3000، 3500، 4000، 3800، 50000. المتوسط = 12,860. هل هذا يُمثل الموظفين؟ بالطبع
شوّه المتوسط تماماً (Outlier) لا! الراتب 50,000

2. Weighted Mean (المتوسط الموزون)

Weighted Mean = $(\sum w \times x) / \sum w$: يعكس أهميتها. الصيغة (Weight) عندما لا تكون كل القيم متساوية الأهمية، تُعطي كل قيمة وزناً

مثال توضيحي:
المتوسط العادي () $3.0 = (2 \times 2 + 4 \times 3) / (2 + 4)$. GPA: A (4.0) مادة ب 3 ساعات بدرجة + C (2.0) مادة ب 1 ساعة بدرجة. (المتوسط الموزون) $3.5 = (1 \times 3 + 2 \times 4) / (1 + 2)$. الموزون أصح لأن المادة ذات الـ 3 ساعات أهم.

(AI Connection): الصلة بالذكاء الاصطناعي

حساب Imbalanced Classes الموزون لمعالجة Loss في حساب الـ ML يظهر في Weighted Mean. المعتمدة على أوزان المتغيرات Gradient Descent متوسطات الأداء الموزونة بحجم كل فئة، خوارزمية

3. Geometric Mean (المتوسط الهندسي)

يُستخدم عند قياس معدلات النمو أو الضرب. $GM = \sqrt[n]{x_1 \times x_2 \times \dots \times x_n}$: للضرب الكلي للقيم. الصيغة n هو الجذر (لا الجمع).

مثال توضيحي:

GM: عائد استثمار على 3 سنوات: +10%، +20%، -5%. المتوسط الحسابي لمعدلات العائد مُضَلَّل. المتوسط الهندسي أي 7.82% سنوياً. هذا الرقم يعكس الواقع الحقيقي للنمو $1.0782 \approx \sqrt[3]{(1.10 \times 1.20 \times 0.95)} = \sqrt[3]{1.254}$ المركب.

4. Harmonic Mean (المتوسط التوافقي)

يُستخدم عند المتوسطات التي تنطوي على نسب. $HM = n / (\sum 1/x_i)$: مقسوماً على مجموع مقلوبات القيم. الصيغة n هو

مثال توضيحي

سرعة رحلة: الذهاب بـ 60 كم/ساعة، العودة بـ 40 كم/ساعة. المتوسط الحسابي = 50 كم/ساعة (خاطئ). المتوسط التوافقي = $2 / (1/60 + 1/40) = 0.0167 / (2) = 0.025 = 2/0.0417 = 48$ كم/ساعة (صحيح)!

(AI Connection) الصلة بالذكاء الاصطناعي

Precision و Recall! $F1 = 2 / (1/Precision + 1/Recall)$ هو المتوسط التوافقي لـ F1-Score الـ ML: في المنخفض جداً Recall أو Precision يُعاقب النماذج ذات الـ F1 هذا يُفسَّر لماذا $F1 = 2 \times P \times R / (P + R)$.

5. الوسيط (Median)

زوجياً، الوسيط n إذا كان $(n+1)/2$ فردياً، الوسيط هو القيمة في الموضع n هو القيمة الوسطى بعد ترتيب البيانات. إذا كان هو متوسط القيمتين الوسطيتين

في مثال الرواتب السابق: 3000، 3500، 3800، 4000، 50000 Outliers! لماذا الوسيط مهم؟ لأنه غير متأثر بالـ. بعد الترتيب الوسيط = 3800. هذا يُمثِّل الموظفين أفضل بكثير من المتوسط 12,860

قاعدة ذهبية

Outliers عند وصف توزيع بيانات الدخل أو الثروة أو أسعار المنازل، استخدم دائماً الوسيط لأن هذه البيانات دائماً لها عالية تثنؤ المتوسط. لهذا الإحصاءات الحكومية تُعبّر عن دخل المنازل بالوسيط لا المتوسط

6. المنوال (Mode)

هو القيمة الأكثر تكراراً. يُستخدم مع البيانات الفئوية والكمية. يمكن أن يكون للبيانات

- منوال واحد: Unimodal
- منوالان: Bimodal
- أكثر من منوالين: Multimodal
- إذا كانت كل القيم مختلفة: No Mode

مثال توضيحي

في هذه الحالة المنوال أهم من المتوسط. $M = \text{المنوال}$. M, L, M, S, M, XL, M, L : المقاسات الأكثر مبيعاً من قميص. لأنك تريد معرفة ما يجب تصنيعه أكثر.

(AI Connection): الصلة بالذكاء الاصطناعي

(تعويض القيم المفقودة). (البيانات الفئوية، القيمة المفقودة تُعوّض بالمنوال Imputation يُستخدم في ML: Mode في البيانات الرقمية، غالباً تُعوّض بالمتوسط أو الوسيط).

7. Trimmed Mean و Winsorized Mean

Trimmed Mean (المتوسط المُقْلَص)

Trimmed Mean % نحذف نسبة معينة من أعلى وأسفل البيانات ثم نحسب المتوسط. مثال: 10% Outliers. يحذف أعلى 10% وأدنى 10% من البيانات. يُعطي مقياساً مقاوماً للـ Mean.

Winsorized Mean

% بدلاً من حذف القيم المتطرفة، تُعيد قيمتها لتصبح مساوية لحدود معينة. مثال: تُعيد أعلى 5% 5th Percentile وأدنى 5% لتصبح مساوية للـ 5th Percentile.

(AI Connection): الصلة بالذكاء الاصطناعي

بأسلوب مدروس بدلاً من حذفها أو الاحتفاظ بها كما هي Outliers لمعالجة ML هذه المقاييس تُستخدم في للبيانات المالية Feature Engineering شائعة في الـ Winsorization.

8. Outliers مقارنة المقاييس وأثر الـ

المقياس	نقاط القوة	نقاط الضعف	متى تستخدمه؟
Mean	يأخذ كل القيم، مناسب للعمليات الجبرية	Outliers متأثر جداً بالـ	توزيع طبيعي، بدون Outliers
Median	Outliers مقاوم للـ	لا يأخذ كل القيم بالاعتبار	البيانات المتحيزة، الدخل، الأسعار
Mode	مناسب للبيانات الفئوية	قد يكون متعدد أو غير موجود	البيانات الفئوية، أكثر القيم شيوعاً

العلاقة بين المقاييس الثلاثة تُخبرك عن شكل التوزيع:

- تماماً (Symmetric) توزيع متماثل: $\text{Mean} = \text{Median} = \text{Mode}$.
- الذيل لليمين - (Positive Skew) انحراف إيجابي: $\text{Mean} > \text{Median} > \text{Mode}$.
- الذيل للييسار - (Negative Skew) انحراف سلبي: $\text{Mean} < \text{Median} < \text{Mode}$.

الفصل الخامس: مقاييس التشتت

مقاييس النزعة المركزية تُخبرنا أين تتمركز البيانات، لكنها لا تُخبرنا كيف تتوزع حول هذا المركز. تخيل مجموعتين من الطلاب: الأولى درجاتهم 70، 75، 80، 85، 90 والمتوسط 80. الثانية درجاتهم 10، 50، 80، 110، 150 والمتوسط أيضاً 80! المتوسط متساوٍ لكن المجموعتان مختلفتان جوهرياً. مقاييس التشتت تُكشف هذا الاختلاف

1. المدى (Range)

أبسط مقاييس التشتت وأسهلها حساباً. نقطة ضعفه: يعتمد فقط. $\text{Range} = \text{Max} - \text{Min}$. الفرق بين أكبر قيمة وأصغر قيمة Outliers. على قيمتين ويتأثر بشدة بالـ

مثال توضيحي:

$\text{Range} = 100 - 60 = 40$: لو أضفنا طالباً بدرجة 100. $\text{Range} = 95 - 60 = 35$. درجات: 60، 70، 75، 80، 95. قيمة واحدة غيرت المقياس بأكمله.

2. الانحراف المعياري (Standard Deviation) والتباين (Variance)

على الإطلاق. دعني أبني فهمك خطوة بخطوة ML هذان المقياسان من أهم المفاهيم في الإحصاء والـ

الفكرة الحدسية: نريد قياس متوسط بُعد القيم عن متوسطها. لو طرحنا كل قيمة من المتوسط، مجموع الفروقات = صفر دائماً (الإيجابية والسلبية تتلغى). (الحل: نُرَبِّع الفروقات)

Variance (التباين)

$\sigma^2 = \sum (x_i - \bar{x})^2 / (n-1)$: متوسط مربعات الانحرافات عن المتوسط. للعينة للعينة؟ لتصحيح التحيز في تقدير التباين من عينة صغيرة $n-1$ لماذا $= \sum (x_i - \mu)^2 / N$. (Bessel's Correction).

Standard Deviation (الانحراف المعياري)

نأخذ الجذر لإعادة الوحدة لنفس وحدة البيانات الأصلية. $s = \sqrt{s^2}$. الجذر التربيعي للتباين. التباين بالدرجة² لكن الانحراف المعياري بالدرجة

مثال توضيحي:

درجات: 70، 75، 80، 90، 65. المتوسط = 76. (الانحرافات: $14^2=196$ ، $1^2=1$ ، $4^2=16$ ، $6^2=36$ ، $11^2=121$). مجموع = 370. التباين = $370/4 = 92.5$. الانحراف المعياري = $\sqrt{92.5} \approx 9.6$. هذا يعني أن معظم الدرجات تقع في نطاق 76 ± 9.6 أي بين 66.4 و 85.6

(AI Connection): الصلة بالذكاء الاصطناعي

أكثر Outliers تحديد الـ Normalization (Z-Score = $(x - \mu)/\sigma$): الانحراف المعياري أساسي في ML: في تفترض أن الأخطاء لها انحراف معياري Linear Regression من المتوسط)، وصف أداء النموذج. نماذج مثل σ من 3 ثابت (Homoscedasticity).

3. الانحراف المطلق عن الوسيط (MAD - Mean Absolute Deviation)

من الانحراف المعياري Outliers هو أقل تأثراً بالـ $MAD = \sum |x_i - \bar{x}| / n$: بدلاً من تربيع الفروقات، نأخذ قيمتها المطلقة (لأننا لا نربّع الفروقات الكبيرة).

4. المدى الربيعي (IQR - Interquartile Range)

لأنه لا يعتمد على القيم القصوى Outliers هو مدى الـ 50% الأوسط من البيانات. مقاوم للـ $IQR = Q3 - Q1$.

مثال توضيحي:
يُخبرنا أن IQR الـ $IQR = 60 - 20 = 40$. $Q1 = 20$ ، $Q3 = 60$. بيانات: 10، 20، 30، 40، 50، 60، 70.
الـ 50% الأوسط منتشر بمقدار 40 وحدة.

(AI Connection): الصلة بالذكاء الاصطناعي
 $IQR = Q3 + 1.5 \times IQR$ أو $Q1 - 1.5 \times IQR$ قيمة) Tukey بطريقة Outliers يُستخدم في: اكتشاف الـ IQR (بدلاً من المتوسط والانحراف المعياري $Q1$ و $Q3$ تحويل البيانات بناءً على) ML في Robust Scaling، (Outlier).

5. معامل الاختلاف (Coefficient of Variation - CV)

يُمثل الانحراف المعياري كنسبة مئوية من المتوسط. فائدته الكبرى: المقارنة بين مجموعات. $CV = (\sigma / \mu) \times 100\%$. بيانات مختلفة الوحدات أو المقاييس

مثال توضيحي:
وزنهم: متوسط 70. $CV = 10/170 \times 100\% = 5.9\%$. طول طلاب: متوسط 170 سم، انحراف معياري 10 سم.
النسبة تُظهر أن الوزن أكثر تشتتاً نسبياً من الطول. $CV = 8/70 \times 100\% = 11.4\%$. كجم، انحراف معياري 8 كجم.

6. تأثير التشتت على نماذج ML

التشتت في البيانات يؤثر مباشرة على أداء النماذج:

- Scaling أخرى → تحتاج Features ذات تشتت عالٍ جداً قد تُسيطر على النموذج وتُخفي تأثير Features
- (Variance Threshold). لا تُضيف معلومة للنموذج → احذفها (Variance ≈ 0) ذات تشتت منخفض جداً Features
- لأنها تحمل Variance نبحث عن الاتجاهات ذات أعلى، (PCA (Principal Component Analysis في أكثر المعلومات

(AI Connection): الصلة بالذكاء الاصطناعي

Feature Selection: Variance. Feature بتباين = صفر) قيمة واحدة هو الـ Features أحد معايير اختيار الـ: Feature Selection ذات التباين المنخفض Features يُزيل الـ sklearn: VarianceThreshold() دائماً (لا تُعلّم النموذج شيئاً. في تلقائياً.

الفصل السادس: الموقع النسبي وتقسيم البيانات

مقاييس النزعة المركزية والتشتت تُخبرنا عن البيانات ككل. لكن ماذا عن قيمة بعينها؟ كيف نعرف موقعها النسبي بين باقي البيانات؟ هذا هو موضوع الموقع النسبي.

1. Percentiles و Quartiles و Deciles

Percentile (المنيني)

من البيانات أقل منها أو مساوياً لها. مثال $P\%$ هو القيمة التي يكون P th Percentile. P th Percentile هي الدرجة في الـ 90. تعني أن 90% من الطلاب حصلوا على درجة أقل منها P th Percentile.

هي النسب المئوية 25، 50، 75 Quartiles الـ

- من البيانات أقل منه 25% (th Percentile: 25) = Q1
- الوسيط: نقطة المنتصف = (th Percentile: 50) = Q2
- من البيانات أقل منه 75% (th Percentile: 75) = Q3

مثال توضيحي

يعني أن الطالب أفضل من 85% من المتقدمين. نفس الدرجة في P th Percentile للطلاب في الـ 85 SNAP Score. يُعطي المعنى النسبي للدرجة P th Percentile. الـ P th Percentile امتحان آخر قد تكون في الـ 60.

2. Z-Score (الدرجة المعيارية)

$Z = \frac{(x - \mu)}{\sigma}$ هو أحد أهم المفاهيم الإحصائية لأنه يُحوّل أي قيمة إلى وحدات الانحراف المعياري. الصيغة Z-Score الـ

القيمة: $Z = +2$. القيمة = المتوسط: $Z = 0$ 'يُجيب على' كم انحراف معياري بعيدة هذه القيمة عن المتوسط؟ Z-Score الـ. القيمة أقل من المتوسط بمقدار 1.5 انحراف معياري: $Z = -1.5$. أعلى من المتوسط بمقدار انحرافين معياريين.

مثال توضيحي

(SD=5، متوسط 70) وعلى 78 في العلوم (SD=10، متوسط الفصل 75) طالب حصل على 85 في الرياضيات. للعلوم $Z = \frac{78-70}{5} = 1.6$. إذن العلوم أفضل نسبياً Z . للرياضيات $Z = \frac{85-75}{10} = 1.0$. أيهما أفضل نسبياً؟
إرغم أن الدرجة المطلقة أقل

(AI Connection) الصلة بالذكاء الاصطناعي

لـمتوسط = 0 وانحراف معياري = 1 feature تحويل كل ML في Standardization هو أساس الـ Z-Score التي تتأثر بمقياس البيانات. في (SVM, KNN, Linear Regression) هذا ضروري لكثير من الخوارزميات. تلقائياً Z-Score Standardization يطبق sklearn: StandardScaler()

3. Outliers اكتشاف الـ

طريقة Tukey (IQR Method)

هذه الطريقة لا تفترض أي توزيع. $Q3 + 1.5 \times IQR$ أو أكبر من $Q1 - 1.5 \times IQR$ إذا كانت: أقل من outlier القيمة وتعمل حتى مع البيانات غير الطبيعية (Non-parametric) للبيانات

القاعدة التجريبية (Empirical Rule)

تقع في 99.7% $\mu \pm 3\sigma$ تقع في نطاق 95% $\mu \pm 2\sigma$ للبيانات ذات التوزيع الطبيعي: 68% من البيانات تقع في نطاق Outliers. تُعتبر $\mu \pm 3\sigma$ القيم خارج نطاق

مبرهنة شيبشيف (Chebyshev's Theorem)

مثال: $\mu \pm k\sigma$ من البيانات تقع في نطاق $100\% \times (1 - 1/k^2)$ تنطبق على أي توزيع (ليس فقط الطبيعي): (على الأقل أقل قوة من القاعدة التجريبية لكن أكثر عمومية. $\mu \pm 2\sigma$ على الأقل 75% من البيانات في نطاق $k=2 \rightarrow$

الطريقة	تفترض توزيعاً؟	متى تستخدمها؟
Z-Score ($ Z > 3$)	نعم (طبيعي)	بيانات موزعة طبيعياً
IQR Method (Tukey)	لا	Outliers أي توزيع، مقاومة للـ
Empirical Rule	نعم (طبيعي)	عند التأكد من التوزيع الطبيعي
Chebyshev's Theorem	لا	ضمانة دنيا لأي توزيع

4. Feature Scaling في ML

(KNN, السبب: خوارزميات كثيرة تعتمد على المسافات. ML من أهم خطوات ما قبل المعالجة في Feature Scaling الـ بقيم من 0 إلى 1 و Features. Feature وهذه تتأثر بمقياس الـ (Gradient Descent) أو المشتقات (SVM) آخر بقيم من 0 إلى 1,000,000 → الثاني سيُسيطر على النموذج Feature

أ. Min-Max Scaling (Normalization)

→ مثال: درجات 0-100. $x_{scaled} = (x - x_{min}) / (x_{max} - x_{min})$. يُحوّل البيانات لنطاق [0, 1]. الصيغة (قيمة شاذة تُفسد المقياس كله) Outliers تُحوّل لـ 0-1. المشكلة: حساس للـ

ب. Standardization (Z-Score Scaling)

لا يُحدد نطاقاً معيناً للقيم لكنه σ . $x_{scaled} = (x - \mu) / \sigma$ يُحوّل البيانات لمتوسط = 0 وانحراف معياري = 1. الصيغة Outliers. أكثر مقاومة للـ

ج. Robust Scaling

الأكثر. $x_{\text{scaled}} = (x - \text{median}) / \text{IQR}$: بدلاً من المتوسط والانحراف المعياري. الصيغة IQR يستخدم الوسيط و. كثيرة Outliers مناسب عندما تكون، Outliers مقاومة للـ.

متى؟	Outliers مقاومة	النطاق	الصيغة	Scaling نوع الـ
الشبكات العصبية، بيانات نظيفة	ضعيفة	[0, 1]	$(x - \min) / (\max - \min)$	Min-Max
الأكثر شيوعاً، معظم الخوارزميات	متوسطة	لا محدود	$(x - \mu) / \sigma$	Standardization
Outliers بيانات بها كثيرة	قوية	لا محدود	$(x - \text{median}) / \text{IQR}$	Robust Scaling

(AI Connection): الصلة بالذكاء الاصطناعي

→ إذا احتجت قيماً في [0, 1]. Standardization. → إذا كانت البيانات طبيعية أو شبه طبيعية: ML قاعدة عامة في
 (Decision Tree, Random Forest) خوارزميات تعتمد على الشجرة. Robust Scaling. → كثيرة Outliers إذا كانت هناك Min-Max. Scaling! لا تحتاج

الفصل السابع: شكل التوزيع

حتى الآن تعلمنا وصف البيانات بأرقام (مقاييس المركزية والتشتت). لكن الأرقام وحدها لا تكفي. شكل التوزيع يُخبرنا عن طبيعة البيانات بعمق أكبر.

1. التماثل والانحراف (Symmetry & Skewness)

مثال: $\text{Mean} = \text{Median} = \text{Mode}$ الشكل متطابق على يمين ومحور الوسيط. الـ (Symmetric) التوزيع المتماثل أطوال البشر.

Positive Skew (الانحراف الإيجابي)

يعني: معظم البيانات منخفضة مع قيم. $\text{Mean} > \text{Median} > \text{Mode}$. الذيل يمتد لليمين. عالية قليلة. مثال: الرواتب، أسعار المنازل، عدد المتابعين على وسائل التواصل.

Negative Skew (الانحراف السلبي)

يعني: معظم البيانات مرتفعة مع قيم. $\text{Mean} < \text{Median} < \text{Mode}$. الذيل يمتد لليسار. منخفضة قليلة. مثال: درجات امتحان سهل (معظم الطلاب حصلوا على درجات عالية).

Skewness = $(\text{Mean} - \text{Mode}) / \text{SD}$ أو $\text{Skewness} = 3(\text{Mean} - \text{Median}) / \text{SD}$ (Pearson's formula). قياسية الانحراف رقمياً. $\rightarrow$ قريبة من صفر. $\rightarrow$ السالبة Negative Skew. $\rightarrow$ القيم الموجبة Positive Skew. تماثل.

(AI Connection): الصلة بالذكاء الاصطناعي

Log Transform $\rightarrow$ Positive Skew: التوزيعات المنحرفة تُسبب مشاكل لبعض النماذج الخطية. الحل: ML الانحراف في الهدف: جعل البيانات. Square Root Transform. Box-Cox Transform. (تقلل تأثير القيم الكبيرة). أقرب للتوزيع الطبيعي لتحسين أداء النموذج.

2. التفرطح (Kurtosis)

Kurtosis = 3 (أو Excess Kurtosis = 0). يقيس 'حدة' قمة التوزيع ووزن الذيل مقارنة بالتوزيع الطبيعي. التوزيع الطبيعي له

النوع	Kurtosis	الشكل	الذيل	مثال
Leptokurtic	> 3	قمة حادة	ثقيلة (Heavy Tails)	عوائد الأسهم
Mesokurtic	$= 3$	التوزيع الطبيعي	عادية	أطوال البشر
Platykurtic	< 3	قمة مسطحة	خفيفة	التوزيع المنتظم

(AI Connection): الصلة بالذكاء الاصطناعي

أكثر شيوعاً. المتوسط Outliers الـ ML: خطرة في (Heavy-Tailed / Leptokurtic) التوزيعات ذات الذيل الثقيلة بدلاً من العمليات الحسابية العادية. بيانات المعاملات Robust Statistics والانحراف المعياري أقل موثوقية. تحتاج Heavy-Tailed المالية والشبكات الاجتماعية غالباً.

3. التوزيع الطبيعي (Normal Distribution)

أو 'منحنى Gaussian Distribution على الإطلاق. يُسمى أيضاً ML التوزيع الطبيعي هو الأكثر أهمية في الإحصاء والـ (Bell Curve) 'الجرس.

خصائصه الجوهرية:

- Mean = Median = Mode: متماثل تماماً حول المتوسط
- (يُحدد الانتشار) σ (يُحدد المركز) والانحراف المعياري μ تحدد معاملاً فقط: المتوسط
- تتبع القاعدة التجريبية: 99.7-95-68
- مساحة المنطقة تحت المنحنى $= 1$ (دالة الكثافة الاحتمالية)

(Standard Normal Distribution) التوزيع الطبيعي المعياري

Z- تحول أي بيانات طبيعية إليه بالـ Z-Distribution. هو التوزيع الطبيعي بمتوسط $= 0$ وانحراف معياري $= 1$. يُسمى هذا التحويل يُسمح لنا باستخدام جداول التوزيع الطبيعي المعياري. $\text{Score: } Z = (X - \mu) / \sigma$

(AI Connection): الصلة بالذكاء الاصطناعي

الغالبية العظمى من نظريات الإحصاء الاستدلالي تفترض التوزيع الطبيعي. أخطاء النماذج ML: التوزيع الطبيعي في موزعة طبيعياً Feature يفترض أن كل Gaussian Naive Bayes. الخطية يُفترض أن تتبع التوزيع الطبيعي تقول أن متوسطات العينات تتوزع طبيعياً حتى لو البيانات الأصلية (Central Limit Theorem) المركزية الحدية ليست طبيعية

4. Long-Tail و Heavy-Tail Distributions

من المنتجات تُؤد 80% من المبيعات 20% Long-Tail: هي مثال على توزيع (Pareto Principle) قاعدة 80/20 من العملاء يُؤلدون 80% من الربح. التوزيعات ذات الذيل الطويل شائعة في الإنترنت والاقتصاد الرقمي 20%

(AI Connection): الصلة بالذكاء الاصطناعي

الذيل الطويل 'يعني أن هناك' Amazon و Netflix مثل (Recommendation Systems) في أنظمة التوصية آلاف المنتجات/الأفلام النادرة الطلب. النماذج التقليدية تُهمل هذا الذيل وتُركز على الأكثر شيوعاً. النماذج الذكية تستطيع التوصية بمحتوى من الذيل الطويل للمستخدمين ذوي الاهتمامات المتخصصة، وهذا ما يُميز أنظمة التوصية المتقدمة

الفصل الثامن: مفاهيم رياضية مهمة للإحصاء الوصفي

فهمها جيداً يُمكنك ML الإحصاء قائم على أسس رياضية. هذه المفاهيم ليست مجرد أدوات حسابية، بل هي لغة الإحصاء والـ من قراءة أي صيغة رياضية بسهولة.

1. الترميز التجميعي (Sigma Notation)

هذا الترميز يُختصر معادلات طويلة في $\sum_{i=1}^n x_i = x_1 + x_2 + \dots + x_n$. تعني 'اجمع'. الصيغة العامة (Sigma) Σ رمز واحد.

مثال توضيحي:

يُوفر Σ $\text{Mean} = (x_1 + x_2 + x_3 + \dots + x_n) / n$. ستكون Σ هذه الصيغة بدون $\text{Mean} = (1/n) \times \sum_{i=1}^n x_i$. هذا التعقيد للصيغ ذات حدود كثيرة أو متغيرة.

مهمة Σ خصائص:

- (الثابت يخرج خارج المجموع) $\Sigma(a \times x_i) = a \times \Sigma x_i$
- (التوزيع على المجموع) $\Sigma(x_i + y_i) = \Sigma x_i + \Sigma y_i$
- (الثابت $\times$ n مرة = $n \times$ مجموع ثابت) $\Sigma c = n \times c$

(AI Connection): الصلة بالذكاء الاصطناعي

Σ وخوارزميات التحسين مليئة بـ Loss Functions معادلات الـ ML، في $\text{MSE Loss} = (1/n) \times \sum (y_i - \hat{y}_i)^2$. مثال Σ . ML يُمكنك من قراءة أي ورقة بحثية في Σ فهم.

2. القيمة المطلقة (Absolute Value)

ومسافة MAD القيمة المطلقة تُزيل الإشارة وتُعطينا المقدار فقط. تُستخدم في $x < 0$ إذا $-x$ أو $x \geq 0$ إذا x $|x| = x$ Manhattan.

3. القوى والجذور والأسس

$\sqrt{x} =$ لجعلها موجبة وإعطاء الفروقات الكبيرة وزناً أكبر Variance مضروبة في نفسها. تُربّع الفروقات في الـ $x^2 = x$ الجذر التربيعي. نأخذ الجذر في الانحراف المعياري لإعادة الوحدة لوحدة البيانات الأصلية.

(AI Connection): الصلة بالذكاء الاصطناعي

تأخذ القيمة المطلقة L1 (MAE) تُربّع الأخطاء → تُعاقب الأخطاء الكبيرة أكثر. خسارة L2 (MSE) خسارة ML: في Overfitting تُستخدم لمنع L2 (Ridge) و L1 (Lasso) Regularization: Outliers. Regularization: L1 (Lasso) و L2 (Ridge) عادلة مع الـ →

4. اللوغاريتمات (Logarithms)

$e \approx 2.718$ كأساس (ln) طبيعي log: الأكثر استخداماً x هو عدد المرات التي تضرب فيها الأساس بنفسه للوصول لـ $\log(x)$.
 خصائص: $\log(a \times b) = \log(a) + \log(b)$. $\log(a/b) = \log(a) - \log(b)$. $\log(a^n) = n \times \log(a)$.

(AI Connection): الصلة بالذكاء الاصطناعي

Log Transform لعلاج Positive Skew. Log Loss (Cross-Entropy Loss) في Classification. Information Theory: Entropy = $-\sum p(x) \times \log(p(x))$. معادلات log. تشمل على Gradient Descent.

5. المسافات الرياضية (Distance Mathematics)

ML: المسافة بين نقطتين هي مفهوم رياضي له تعريفات متعددة في الـ

نوع المسافة	الصيغة	متى تستخدمها؟
Euclidean	$\sqrt{\sum (x_i - y_i)^2}$	KNN, K-Means, أكثر أنواع المسافات استخداماً
Manhattan	$\sum x_i - y_i $	مناسبة للبيانات، Outliers مقاومة للـ ذات الأبعاد الكثيرة
Cosine	$1 - (x \cdot y) / (x \times y)$	مقارنة الاتجاهات، معالجة النصوص (NLP)

6. النسب والتناسب (Ratios & Proportions)

النسبة هي مقارنة كمية بأخرى. التناسب هو نسبة جزء من الكل. هذان المفهومان أساسيان في: حساب التكرار النسبي (Relative Frequency = f/n). تقييم أداء النماذج (Precision = $TP/(TP+FP)$).

Python الفصل التاسع: الإحصاء الوصفي باستخدام

تُوفّر مكتبات قوية تُنفّذ كل ما تعلمناه بأسطر قليلة من Python. التطبيق العملي هو ما يُحوّل الفهم النظري إلى مهارة حقيقية الكود.

1. NumPy - الأساس الرياضي

تقريباً مبنية فوقها ML هي مكتبة الحساب الرقمي الأساسية. كل مكتبة NumPy (Numerical Python)

العمليات الأساسية

للإحصاء الوصفي Python - NumPy كود

```
import numpy as np # إنشاء مصفوفة
data = np.array([23, 45, 67, 12, 89, 34, 56, 78, 45, 23, 34, 56]) # المتوسط
print('المتوسط:', np.mean(data)) # 46.83
print('الوسيط:', np.median(data)) # 45.0
print('الانحراف المعياري:', np.std(data)) # الانحراف المعياري
print('تباين:', np.var(data, ddof=1)) # ddof=1
print('تباين:', np.var(data, ddof=1)) # التباين
print('لحساب تباين العينة')
print('الربيع الأول:', np.percentile(data, 25)) # Q1
print('الربيع الثالث:', np.percentile(data, 75)) # Q3
print('المرتبة 90:', np.percentile(data, 90))
print('الحد الأدنى:', np.min(data))
print('الحد الأقصى:', np.max(data))
print('المدى:', np.ptp(data)) # ptp = peak to peak = max - min
```

n بدلاً من n-1 للعينة نستخدم ddof = Degrees of Freedom. في الانحراف المعياري للعينة؟ ddof=1 لماذا لتصحيح التحيز في تقدير تباين المجتمع من عينة أصغر (Bessel's Correction)

2. Pandas - تحليل البيانات الجدولية

ML في EDA هي الأداة الأساسية للـ (DataFrames) هي مكتبة التعامل مع الجداول Pandas

إحصاءات شاملة بسطر واحد - describe() دالة

Python - Pandas describe() كود

```
import pandas as pd # إنشاء DataFrame
df = pd.DataFrame({'العمر': [45, 28, 32, 25], 'الراتب': [35, 28, 42, 31], 'سنوات': [7500, 12000, 5500, 9000, 15000, 6000, 8000, 5000]})
print(df.describe()) # count, mean, std, min, Q1, median, Q3, max
df_cat = pd.DataFrame({'مبيعات': [1, 2, 3, 4, 5], 'هندسة': ['IT', 'هندسة']})
print(df_cat.describe()) # count, unique, top (mode), freq
```

std (المتوسط)، mean (عدد القيم غير المفقودة)، count: تُلخّص 8 إحصاءات في ثانية واحدة describe() دالة هذا هو أول شيء تفعله عند فتح أي max، (Q3) (% الوسيط)، 75 %، 25% (Q1)، min، (الانحراف المعياري) Dataset.

groupby() و value_counts()

Python - value_counts و groupby كود

```
import pandas as pd
df = pd.DataFrame({
    'القسم': ['مبيعات', 'هندسة', 'مبيعات', 'هندسة', 'مبيعات', 'هندسة', 'مبيعات', 'هندسة', 'مبيعات', 'هندسة'],
    'الراتب': [5500, 9000, 15000, 6000, 8000, 5000, 5500, 9000, 15000, 6000],
    'الأداء': ['جيد', 'ممتاز', 'مقبول', 'ممتاز', 'مقبول', 'ممتاز', 'مقبول', 'ممتاز', 'مقبول', 'ممتاز']
})
# value_counts: قيمة فئوية لكل تكرار
print(df['القسم'].value_counts())
# كنسب مئوية
print(df['القسم'].value_counts(normalize=True))
# groupby: تحليل إحصائي حسب مجموعات
print(df.groupby('الراتب')['القسم'].mean())
# IT: 15000, 5500: 8500
print(df.groupby('الراتب')['القسم'].agg(['mean', 'min', 'max', 'std']))
```

(AI Connection): الصلة بالذكاء الاصطناعي

جديدة بناءً على features إنشاء 'Aggregation Features' بـ ML هو ما يُسمى في Pandas في groupby() جميع البيانات. مثال: بدلاً من 'راتب الموظف'، تُنشئ 'متوسط راتب قسمه'، 'أعلى راتب في قسمه'، وغيرها. هذه الـ الجديدة قد تكون أقوى بكثير في التنبؤ Features.

مكتبات التصور البياني 3.

الأساس - Matplotlib

Python - Matplotlib كود

```
import matplotlib.pyplot as plt
import numpy as np
data = np.random.normal(70, 10, 200)
# 200 درجة موزعة طبيعياً
fig, axes = plt.subplots(1, 3, figsize=(15, 4))
# Histogram
axes[0].hist(data, bins=15, color='steelblue', edgecolor='white')
axes[0].set_title('Histogram')
axes[0].axvline(np.mean(data), color='red', linestyle='--', label='Mean')
axes[0].axvline(np.median(data), color='green', linestyle='--', label='Median')
axes[0].legend()
# Box Plot
axes[1].boxplot(data)
axes[1].set_title('Box Plot')
# Line Plot (Sorted)
sorted_data = np.sort(data)
axes[2].plot(sorted_data)
axes[2].set_title('Sorted Values')
plt.tight_layout()
plt.show()
```

إحصاءات بصرية متقدمة - Seaborn

Python - Seaborn كود

```
import seaborn as sns import pandas as pd import matplotlib.pyplot as plt # Dataset جاهز من Seaborn df = sns.load_dataset('tips') # بيانات مطعم fig, axes = plt.subplots(2, 2, figsize=(12, 10)) # 1. Violin Plot sns.violinplot(x='day', y='total_bill', data=df, ax=axes[0,0]) axes[0,0].set_title('توزيع الفاتورة حسب اليوم') # KDE Plot sns.kdeplot(df['total_bill'], ax=axes[0,1], fill=True) axes[0,1].set_title('كثافة توزيع الفاتورة') # 3. Scatter Plot مع Regression sns.scatterplot(x='total_bill', y='tip', data=df, ax=axes[1,0]) axes[1,0].set_title('العلاقة بين الفاتورة والإكرامية') # Correlation Heatmap corr = df[['total_bill', 'tip', 'size']].corr() sns.heatmap(corr, annot=True, cmap='coolwarm', ax=axes[1,1]) axes[1,1].set_title('مصفوفة الارتباط') plt.tight_layout() plt.show()
```

رسوم تفاعلية - Plotly

Python - Plotly كود

```
import plotly.express as px import plotly.graph_objects as go import pandas as pd df = px.data.tips() # Histogram تفاعلي fig1 = px.histogram(df, x='total_bill', nbins=20, title='توزيع الفواتير', labels={'total_bill': 'قيمة الفاتورة'}) fig1.show() # Box Plot تفاعلي fig2 = px.box(df, x='day', y='total_bill', color='time', title='توزيع الفواتير حسب اليوم', and the plot will show the distribution of total bills by day, colored by time. # Scatter Plot تفاعلي fig3 = px.scatter(df, x='total_bill', y='tip', color='sex', size='size', title='العلاقة بين الفاتورة والإكرامية', trendline='ols') fig3.show()
```

متى تستخدم أي مكتبة؟

للتحليل الإحصائي السريع مع Seaborn: عندما تريد تحكماً كاملاً في كل تفصيلة، للبحث العلمي والنشر: Matplotlib: وتطبيقات الويب Dashboards عندما تحتاج رسوماً تفاعلية، للعروض والـ EDA: Plotly: جمالية عالية، مثالية للـ

كاملة EDA: مثال تكاملي 4.

كامل Python - Exploratory Data Analysis كود

```
import pandas as pd import numpy as np import seaborn as sns import matplotlib.pyplot as plt from scipy import stats # فهم الهيكل df = sns.load_dataset('iris') # 1. df.shape print('الشكل:', df.shape) # 2. df.columns.tolist() print('الأعمدة:', df.columns.tolist()) # 3. df.dtypes print('الأنواع:', df.dtypes) # 4. df.describe() print('الإحصاءات الوصفية:', df.describe()) # 5. df.isnull().sum() print('القيم المفقودة:', df.isnull().sum()) # 6. fig, axes = plt.subplots(2, 2, figsize=(12, 10)) for i, col in enumerate(df.select_dtypes(include=np.number).columns): ax = axes[i//2, i%2] sns.histplot(df[col], kde=True, ax=ax) ax.set_title(f'توزيع {col}') # Z-Score skew = df[col].skew() ax.annotate(f'Skewness: {skew:.2f}', xy=(0.7, 0.9), xycoords='axes fraction') plt.tight_layout() plt.show() # 7. Q1 = df[col].quantile(0.25) Q3 = df[col].quantile(0.75) IQR = Q3 - Q1 outliers =
```



```
df[(df[col] < Q1 - 1.5*IQR) | (df[col] > Q3 + 1.5*IQR)]    print(f'{col}: {len(outliers)} قيمة
# === شاذة === plt.figure(figsize=(8, 6))
sns.heatmap(df.corr(numeric_only=True), annot=True, cmap='coolwarm', center=0)
plt.title('مصفوفة الارتباط') plt.show()
```

(AI Connection): الصلة بالذكاء الاصطناعي

الكامل: فهم الهيكل، الإحصاءات الوصفية، اكتشاف القيم المفقودة، رسم التوزيعات، اكتشاف الـ EDA هذا الكود يُمثل الـ
قبل بناء أي نموذج ML ومصفوفة الارتباط. هذه الخطوات الست يجب تنفيذها في كل مشروع Outliers،

ملخص المذكرة الأولى: الصورة الكاملة

بعد إتمام هذه المذكرة، يجب أن تكون قادراً على رؤية الإحصاء الوصفي كمنظومة متكاملة وليس مجرد مجموعة مفاهيم منفصلة. دعنا نربط كل شيء

خريطة المفاهيم

المرحلة	ماذا تفعل؟	الفصل	Python الأدوات في
1. فهم البيانات	ما نوع بياناتك؟ من أين جاءت؟ ما مستوى قياسها؟	1	df.dtypes, df.info()
2. تنظيم البيانات	جدولة التوزيعات، تجميع الفئات	2	value_counts(), pd.cut()
3. التصور البياني	رسم التوزيعات، اكتشاف الأنماط والشذوذات	3	sns, plt, plotly
4. المركزية	أين تتمركز البيانات؟	4	mean(), median(), mode()
5. التشتت	كيف تنتشر البيانات؟	5	std(), var(), IQR
6. الموقع النسبي	أين تقع قيمة معينة نسبياً؟	6	percentile(), Z-score
7. شكل التوزيع	هل البيانات طبيعية؟ منحرفة؟	7	skewness(), kurtosis()

الأسئلة التي يجب عليها الإحصاء الوصفي

- ما متوسط ووسيط بياناتي؟ (النزعة المركزية)
- كم هي منتشرة؟ (التشتت)
- (Outliers) هل هناك قيم شاذة؟
- (Skewness, Kurtosis) ما شكل التوزيع؟
- (Percentiles, Z-Score) كيف تبدو بيانات معينة نسبةً لباقي البيانات؟
- (Correlation) ما العلاقة بين المتغيرات؟

الصلة بالمذكرات القادمة

هذه المذكرة الأولى وضعت الأساس. المذكرات التالية ستبني عليها

ما القادم بعد الإحصاء الوصفي؟

كيف تُقدّر احتمالية الأحداث؟ ما: (Probability & Distributions) المذكرة الثانية سنتناول الاحتمالات والتوزيعات ؟ المذكرة الثالثة سنتناول ML ؟ كيف تُستخدم في (Binomial, Poisson, Normal) التوزيعات الاحتمالية الشائعة ،كيف نُعيّم من العينة للمجتمع؟ الاختبارات الإحصائية، فترات الثقة: (Inferential Statistics) الإحصاء الاستدلالي كيف نُقيّم أداء نموذجك إحصائياً؟ p-values.

نصيحة ختامية للمذكرة الأولى

ليست مجرد صيغة؛ هي 'متوسط مسافة نقاط البيانات Standard Deviation لا تحفظ الصيغ. افهم الحدس خلفها. الـ ليس مجرد حساب؛ هو 'كم انحراف معياري بعيد هذا الرقم عن المتوسط؟'. عندما تفهم Z-Score عن مركزها. 'الـ الحدس، الصيغ ستبدو واضحة ومنطقية ولن تنساها أبداً